

# Den multiple lineære regressionsmodel (MLR)

Økonometri A

---

Bertel Schjerning

”

# Program

Motivation (W3.1)

MLR på matrix form (W.E2)

Egenskaber ved MLR (W3.2)

Frisch-Waugh's Teorem

Fordelingen af OLS estimaterne (W3.3-W3.4)

Middelrethed

Irrelevante og udeladte variable

Varians og standard fejl for OLS

OLS er BLUE (W3.5, W3.A6)

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

# Motivation

---

# Motivation

Indtil videre har vi undersøgt sammenhænge mellem et outcome ( $y$ ) og en enkelt forklarende variabel ( $x$ ).

Nu udvider vi dette til flere forklarende variable:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + u$$

## Notation:

- $y$  - den afhængige variabel
- $x_1, \dots, x_k$  - de  $k$  forklarende variable
- $\beta_0$  - konstantled
- $\beta_1, \dots, \beta_k$  - hældningskoefficienter
- $u$  - fejllæddet
- $k$  - antallet af forklarende variable,  $k + 1$  parametre i alt

## Motivation: Hvorfor MLR?

- Ofte er der flere faktorer som påvirker  $y$ 
  - MLR kan eksplicit kontrollere for flere faktorer
  - Disse faktorer er ikke længere inkluderet i  $u$
  - Ofte lettere at få opfyldt antagelsen om  $E(u|x) = 0$
- Det gør det lettere at lave ceteris paribus fortolkninger
  - Vi kan nu eksplicit holde faktorerne  $x_2, \dots, x_k$  faste, når vi bestemmer effekten af at ændre  $x_1$  med en enhed.
- Mulighed for mere fleksibel modellering af funktionelle former

## Motivation: Hvorfor MLR?

Hvis vi holder alle øvrige forklarende variable konstante undtagen  $x_j$ :

$$\Delta \hat{y} = \hat{\beta}_j \Delta x_j$$

MLR muliggør “ceteris paribus” fortolkninger, selvom vi i data ikke kan holde alle faktorer konstante.

Vi siger, at vi “kontrollerer for de øvrige effekter”.

## Motivation: Hvorfor MLR?

Mulighed for mere fleksibel modellering af funktionelle former

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_1^2 + u$$

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 \cdot x_2 + u$$

Med  $x_1^2$  eller  $x_1 \cdot x_2$  bliver sammenhængen mellem  $y$  og  $x$ 'erne ikke-lineær:

$$dE(y|X)/dx_1 = \beta_1 + 2\beta_2 x_1$$

$$dE(y|X)/dx_1 = \beta_1 + \beta_3 x_2$$

(hvis  $dE(u|X)/dx_1 = 0$ )

**OBS:** Modellerne er stadig **lineær i parameterne**





- **Jupyter Notebook:** `03_mlr_examples.ipynb`
- **Python Module:** `mymlr.py`
- **Part 1:** Timeløn, uddannelse og erfaring (OLS Estimation)

Let's implement the empirical example!

## MLR på matrix form

---

# Den multiple lineære regressionsmodel

Som ved SLR kan vi udlede OLS som en momentestimator (MM).

Vi har momenterne:

$$E(u|X) = 0 \Rightarrow$$

$$E(u) = 0$$

$$E(ux_j) = 0 \quad \text{for alle } j$$

Vi har altså  $k + 1$  momentbetingelser og samme antal parametre.

## MLR på matrix form (Se appendiks E1.)

Alle observationer:

$$y_1 = \beta_0 + \beta_1 x_{11} + \beta_2 x_{21} + \cdots + \beta_k x_{k1} + u_1$$

$$\vdots$$

$$y_n = \beta_0 + \beta_1 x_{1n} + \beta_2 x_{2n} + \cdots + \beta_k x_{kn} + u_n$$

På matrix form:

$$\begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{k1} \\ \vdots & & & \vdots \\ 1 & x_{1n} & \cdots & x_{kn} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} + \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix}$$

Modellen kan nu skrives som

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$$

## Udledningen af OLS estimatoren

Det teoretiske moment ( $k + 1$  momenter)

$$E(\mathbf{X}'\mathbf{u}) = \mathbf{0}$$

Vi finder OLS ved at erstattet dette med det empiriske moment

$$\frac{1}{n}\mathbf{X}'\hat{\mathbf{u}} = \mathbf{0}$$

hvor  $\hat{\mathbf{u}} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}$ . Dette er  $k + 1$  ligninger. Udledning

$$\begin{aligned}\frac{1}{n}\mathbf{X}'\hat{\mathbf{u}} &= \mathbf{0} \Leftrightarrow \\ \mathbf{X}'(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) &= \mathbf{0} \Leftrightarrow \\ \mathbf{X}'\mathbf{y} &= \mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}}\end{aligned}$$

Hvis  $\mathbf{X}$  har fuld rang, så eksisterer  $(\mathbf{X}'\mathbf{X})^{-1}$

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

## OLS som minimizer af kvadrerede residualer (1/2)

OLS estimatoren findes ved at minimere de kvadrerede residualer:

$$\min_{\beta} \sum_{i=1}^n \hat{u}_i^2 = \min_{\beta} \sum_{i=1}^n (y_i - \mathbf{x}_i' \beta)^2$$

På matrixform:

$$\min_{\beta} \hat{\mathbf{u}}' \hat{\mathbf{u}} = \min_{\beta} (\mathbf{y} - \mathbf{X}\beta)' (\mathbf{y} - \mathbf{X}\beta)$$

Dette er summen af kvadrerede residualer, som vi ønsker at minimere med hensyn til  $\beta$ .

## OLS som minimizer af kvadrerede residualer (2/2)

Førsteordensbetingelser (FOC):

$$\frac{\partial}{\partial \beta} [(\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta)] = \mathbf{0}$$

Udregning af gradienten giver:

$$\begin{aligned} -2\mathbf{X}'(\mathbf{y} - \mathbf{X}\hat{\beta}) &= \mathbf{0} \\ \mathbf{X}'\mathbf{y} &= \mathbf{X}'\mathbf{X}\hat{\beta} \end{aligned}$$

Dette fører til samme OLS estimator:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

Bemærk, at FOC leder til de samme empiriske momentbetingelser som momentmetoden:

$$\frac{1}{n}\mathbf{X}'\hat{\mathbf{u}} = \mathbf{0}, \quad \text{hvor } \hat{\mathbf{u}} = \mathbf{y} - \mathbf{X}\hat{\beta}$$

# Udledningen af OLS estimatoren

Hvornår har en matrix fuld rang?

Søjlerne i  $\mathbf{X}$  skal være lineært uafhængige.

Eksempler på matricer, der ikke har fuld rang:

- Hvis der er en variabel, som er konstant:  
Fx inkluderer  $x = \text{år}$  i en cross-section regression.
- Hvis der findes en lineær relation mellem to eller flere variable:  
Fx inkluderer alder og fødselsår i en cross-section regression.  
$$\text{fødselsår} + \text{alder} = \text{året (som er konstant)}.$$
- I begge tilfælde antager vi, at der er et konstantled i modellen.

Dvs. hvis vi observerer, at ældre mennesker har en højere løn i et cross-section datasæt, kan vi ikke sige om det skyldes alder eller en fødselsårseffekt.



# QR Decomposition og lineær afhængighed

**QR Decomposition:** En matrix  $\mathbf{X}$  kan opdeles som:

$$\mathbf{X} = \mathbf{QR}$$

- $\mathbf{Q}$ : Ortogonal matrix med ortonormale kolonner ( $\mathbf{Q}'\mathbf{Q} = \mathbf{I}$ ).
- $\mathbf{R}$ : Øvre triangulær matrix (alle elementer under diagonalen er 0).

**Lineær afhængighed:**

- Diagonalelementer i  $\mathbf{R}$  tæt på 0 betyder, at variablen er lineært afhængig.
- Afhængige variable fjernes for at sikre, at  $\mathbf{X}$  har fuld rang.

**Anvendelse i regression:**

- QR decomposition bruges til at sikre, at designmatricen har fuld rang, hvilket er nødvendigt for at estimere OLS koefficienterne.



- **Jupyter Notebook:** `03_mlr_examples.ipynb`
- **Part 2:** Timeløn, uddannelse og erfaring  
(OLS estimator og rangbetingelsen)

## Egenskaber ved MLR

---

# Egenskaberne ved MLR

Mange af egenskaberne fra SLR gælder også for MLR:

**Prædikterede værdier:**

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \cdots + \hat{\beta}_k x_k \quad (\text{elementform})$$

$$\hat{y} = \mathbf{X}\hat{\beta} \quad (\text{matrixform})$$

**For MLR med konstantled gælder:**

- $\sum_{i=1}^n \hat{u}_i = 0$  eller  $\mathbf{1}'\hat{\mathbf{u}} = 0$
- $\sum_{i=1}^n \hat{u}_i x_{ji} = 0$  eller  $\mathbf{X}'\hat{\mathbf{u}} = \mathbf{0}$
- Regressionslinjen går gennem  $(\bar{y}, \bar{x}_1, \dots, \bar{x}_k)$ :

$$\bar{y} = \hat{\beta}_0 + \sum_{j=1}^k \hat{\beta}_j \bar{x}_j \quad \text{eller} \quad \bar{\mathbf{y}} = \bar{\mathbf{X}}\hat{\beta}$$

Vi kan udregne goodness of fit:

$$R^2 = \frac{SSE}{SST} = 1 - \frac{SSR}{SST}$$

hvor:

$$SST \equiv \sum_{i=1}^n (y_i - \bar{y})^2 = (\mathbf{y} - \bar{y})(\mathbf{y} - \bar{y})'$$

$$SSE \equiv \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = (\hat{\mathbf{y}} - \bar{y})(\hat{\mathbf{y}} - \bar{y})'$$

$$SSR \equiv \sum_{i=1}^n \hat{u}_i^2 = \hat{\mathbf{u}}'\hat{\mathbf{u}}$$

**Om  $R^2 \in [0, 1]$ :**

- Jo højere  $R^2$ , jo mere af variationen er forklaret.
- Flere variable vil altid få  $R^2$  til at stige (eller være uændret).
- $R^2$  alene kan ikke afgøre antallet af variable i modellen.

## Justeret goodness-of-fit

Netop fordi  $R^2$  altid vil stige ved flere variable i modellen, beregner Stata også et justeret  $R^2$ :

$$\bar{R}^2 = 1 - \frac{SSR/(n - k - 1)}{SST/(n - 1)} = 1 - \frac{SSR}{SST} \cdot \frac{n - 1}{n - k - 1}$$

- $\bar{R}^2$  “straffer” for mange forklarende variable.
- $\bar{R}^2$  stiger kun, hvis de nye variable forklarer tilstrækkeligt meget af variationen i data.
- $\bar{R}^2$  kan være negativ.

Mere om det i Wooldridge kapitel 6.3.

# Egenskaberne ved MLR: Frisch-Waugh's Teorem

Estimatoren af den multiple regressionsmodel kan foretages ved to regressionsestimationer.

## Model:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + u$$

$\hat{\beta}_j$  kan bestemmes ved to simple lineære regressioner:

## Procedure:

1. Regresser  $x_j$  på alle de andre  $x$ 'er (inkl. konstantled), og gem residualerne som  $\hat{r}_j$ .
2. Regresser  $y$  på  $\hat{r}_j$  for at få  $\hat{\beta}_j$ .

## Resultat:

- Estimatet  $\hat{\beta}_j$  fra trin 2 er det samme som koefficienten til  $x_j$  i den fulde model.

# Egenskaberne ved MLR: Frisch-Waugh Teorem (Matrix form)

**Model:**

$$\mathbf{y} = \mathbf{X}_1\beta_1 + \mathbf{X}_2\beta_2 + \mathbf{u}$$

$\hat{\beta}_1$  kan bestemmes ved hjælp af to regressioner:

**Procedure:**

1. Regresser  $\mathbf{X}_1$  på  $\mathbf{X}_2$ , og gem residualerne som  $\mathbf{r}_1 = \mathbf{X}_1 - \mathbf{X}_2\hat{\gamma}$ :

$$\hat{\gamma} = (\mathbf{X}_2'\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{X}_1$$

2. Regresser  $\mathbf{y}$  på  $\mathbf{r}_1$  for at få  $\hat{\beta}_1$ :

$$\hat{\beta}_1 = (\mathbf{r}_1'\mathbf{r}_1)^{-1}\mathbf{r}_1'\mathbf{y}$$

**Resultat:** Estimatet  $\hat{\beta}_1$  fra trin 2 er det samme som koefficienten til  $\mathbf{X}_1$  i den fulde model.



# Egenskaberne ved MLR: Frisch-Waugh's Theorem

## Trin 1:

Regresser  $x_j$  på alle de andre  $x$ 'er og gem residualerne som  $\hat{r}_j$ :

$$x_j = \gamma_0 + \gamma_1 x_1 + \gamma_2 x_2 + \cdots + \gamma_{j-1} x_{j-1} + \gamma_{j+1} x_{j+1} + \cdots + \gamma_n x_n + r_j$$

Residualerne er  $\hat{r}_j = x_j - \hat{x}_j$ .

## Trin 2:

Regresser  $y$  på  $\hat{r}_j$ :

$$y = \delta_0 + \beta_j \hat{r}_j + e$$

OLS estimatoren for  $\hat{\beta}_j$  fås som:

$$\hat{\beta}_j = \frac{\sum_{i=1}^n y_i \hat{r}_{ji}}{\sum_{i=1}^n \hat{r}_{ji}^2} = \frac{\sum_{i=1}^n (y_i - \bar{y})(\hat{r}_{ji} - \bar{\hat{r}}_{ji})}{\sum_{i=1}^n (\hat{r}_{ji} - \bar{\hat{r}}_{ji})^2}$$

I skal vise dette i den første obligatoriske opgave.



**Let's implement the Frisch-Waugh theorem in Python!**

- Use Jupyter Notebook: `03_mlr_examples.ipynb`
- Part 3: Timeløn, uddannelse og erfaring (Frisch-Waugh)

## Frisch-Waugh Teorem: Intuition

I SLR estimerer vi  $\beta_j$  uden at kontrollere for andre variable:

$$\hat{\beta}_j^{SLR} = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_{ji} - \bar{x}_j)}{\sum_{i=1}^n (x_{ji} - \bar{x}_j)^2}$$

I MLR estimeres  $\beta_j$  ved at fjerne variationen i  $x_j$ , som er korreleret med de øvrige variable:

$$\hat{\beta}_j^{MLR} = \frac{\sum_{i=1}^n (y_i - \bar{y})(\hat{r}_{ji} - \bar{\hat{r}}_j)}{\sum_{i=1}^n (\hat{r}_{ji} - \bar{\hat{r}}_j)^2}$$

MLR kontrollerer altså for andre  $x$ -variable ved at bruge residualer  $\hat{r}_{ji}$  fra en regression af  $x_j$  på de andre variable.

## Frisch-Waugh Teorem: Intuition

Hvorfor giver det mening?

Den forventede værdi af SLR-estimatet:

$$E(\hat{\beta}_j|X) = \beta_j + \frac{\sum_{i=1}^n (x_i - \bar{x}) E(u|X)}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (1)$$

Estimatet er ikke middelret, hvis  $x_j$  er korreleret med  $u$ , som indeholder effekten af de øvrige  $x$ 'er.

Ved at bruge residualerne fra regressionen af  $x_j$  på de andre  $x$ 'er, fjerner vi denne korrelation.

→ Forsøg på at "rense data for dårlig variation".

## Frish-Waugh's Theorem: Anvendelse

Frish-Waugh's Theorem kan blandt andet bruges til at visualisere data selvom modellen indeholder mange forklarende variable.

- I MLR er korrelationen mellem  $x_j$  og  $y$  ikke (altid) informative om den partielle effekt af  $x_j$  og  $y$ .
- Noget af korrelationen skyldes i stedet andre  $x$ 'er, som vi gerne vil kontrollere for.

Derfor:

- I stedet for at plotte  $x_j$  og  $y$ , bør vi plotte  $\hat{r}_j$  og  $y$ .
- På den måde kan vi fx validere den funktionelle form.

Derudover skal vi se at intuitionen fra Frish-Waugh's går igen i mange af vores senere udledninger.

# Partial Linear Models: Robinson Estimator (IKKE PENSUM)

Samme idé kan bruges for mere *partiel lineære modeller*, som bygger videre på intuitionen fra Frisch-Waugh Teoremet.

$$y = \mathbf{X}\beta + g(Z) + u$$

Robinson Estimatoren bruges til at estimere  $\beta$  i en model med en lineær og en ikke-lineær komponent.

## Trin:

1. Estimér  $E(y|Z)$  og  $E(\mathbf{X}|Z)$  ikke-parametrisk (fx kernel regression eller splines).
2. Få residualerne  $y^* = y - E(y|Z)$  og  $\mathbf{X}^* = \mathbf{X} - E(\mathbf{X}|Z)$ .
3. Regresser  $y^*$  på  $\mathbf{X}^*$  for at estimere  $\beta$ .

Fordelen ved Robinson Estimatoren er, at vi kan estimere  $\beta$  uden samtidigt at skulle estimere en specifik form af  $g(Z)$ .

## Fordelingen af OLS estimerterne

---

# Centrale antagelser for den multiple lineære regressionsmodel

MLR.1 Populationsmodellen er lineær i parametrene:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

På matrixform:  $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$

MLR.2 Tilfældig udvælgelse:

Vi har tilfældigt udvalgte og uafhængige observationer af variableerne  $(x_i, y_i) : i = 1, \dots, n$  fra en population.

MLR.3 Ingen perfekt multikollinearitet mellem de forklarende variable:  
I datasættet skal  $\mathbf{X}$  have fuld rang.

MLR.4 Den betingede middelværdi af fejleddet skal være 0:

$$E(u|x_1, x_2, x_2, \dots, x_k) = 0.$$

På matrixform:  $E(\mathbf{u}|\mathbf{X}) = \mathbf{0}$



## Hvad betyder MLR.4?

Hvis MLR.4 er opfyldt, gælder:

$$E(ux_j) = 0 \quad \text{for } j = 1, \dots, k$$

Altså er fejlleddet ukorreleret med alle de forklarende variable.

Eksempler på at **MLR.4** ikke er opfyldt:

- Udeladte variable (der vil være indeholdt i  $u$ ) som er korreleret med de forklarende variable.
- Forkert funktionel form (se kap. 9).
- Målefejl i de forklarende variable (se kap. 9).

Når MLR.4 er opfyldt, er de forklarende variable **eksogene**. Hvis  $x_j$  derimod er korreleret med  $u$ , kaldes  $x_j$  for **endogen**.

## Teorem 3.1: Middelrethed af OLS estimatoren

Under antagelse af MLR.1–MLR.4 er OLS estimatoren **middelret**:

$$E(\hat{\beta}_j) = \beta_j \quad \text{for } j = 0, 1, 2, \dots, k$$

for alle værdier af  $\beta_j$ .

## Hvad betyder det, at OLS er middelret?

- OLS estimatoren er **i gennemsnit** korrekt, hvis vi gentager estimationen på uendeligt mange stikprøver.
- Den forventede værdi af estimatorne vil være lig de sande parametre.
- På ethvert givet stikprøvedatasæt kan der være små afvigelser fra den sande værdi.

# Middelrethed af OLS estimatoren: Bevis

Ingredienser til bevis:

1. **Regneregler** (**A** matrix, **x** stok. vektor, **b** vektor):

1.1  $\mathbf{A}\mathbf{A}^{-1} = \mathbf{I}$  og  $\mathbf{A}^{-1}\mathbf{A} = \mathbf{I}$

1.2  $E(\mathbf{b} + \mathbf{A}\mathbf{x}) = \mathbf{b} + \mathbf{A}E(\mathbf{x})$

2. **Antagelser:**

2.1 MLR.1 (Model):  $\mathbf{y} = \mathbf{X}\beta + \mathbf{u}$

2.2 MLR.2: Tilfældig udvalgt datasæt med  $n$  observationer

2.3 MLR.3:  $\mathbf{X}$  har fuld rang

2.4 MLR.4:  $E(\mathbf{u}|\mathbf{X}) = \mathbf{0}$

3. **OLS Estimator:**

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

# Middelrethed af OLS estimatoren: Bevis (1/2)

## 1. Start med OLS estimatoren:

Fra OLS estimatoren ved vi, at:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

## 2. Erstat $\mathbf{y}$ med modellen (MLR.1):

Fra MLR.1:  $\mathbf{y} = \mathbf{X}\beta + \mathbf{u}$ , så vi kan skrive:

$$\begin{aligned}\hat{\beta} &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \mathbf{u}) \\ &= \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}\end{aligned}$$

Dette udtryk er kun gyldigt, hvis  $\mathbf{X}$  har fuld rang (MLR.3).

## Middelrethed af OLS estimatoren: Bevis (2/2)

### 3. Tag forventning betinget på $\mathbf{X}$ (MLR.4):

Fra MLR.4 ved vi, at  $E(\mathbf{u}|\mathbf{X}) = \mathbf{0}$ .

$$E(\hat{\beta}|\mathbf{X}) = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'E(\mathbf{u}|\mathbf{X}) = \beta$$

### 4. Brug loven om itereret forventning (MLR.2):

Med tilfældigt udvalgte observationer og uafhængighed kan vi bruge loven om itereret forventning til at fjerne betingningen på  $\mathbf{X}$ :

$$E(\hat{\beta}) = E \left[ E(\hat{\beta}|\mathbf{X}) \right] = E[\beta] = \beta$$

### Konklusion:

OLS estimatoren er middelret, dvs.  $E(\hat{\beta}) = \beta$ .

## Inklusion af irrelevante variable

Hvad sker der, hvis man inkluderer en irrelevant variabel?

Antag at den “sande model” opfylder MLR.1-MLR.4 og er:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u$$

Men vi estimerer en model, som også inkluderer  $x_3$ , så:

$$y = \tilde{\beta}_0 + \tilde{\beta}_1 x_1 + \tilde{\beta}_2 x_2 + \tilde{\beta}_3 x_3 + \tilde{u}$$

**Spørgsmål:** Hvordan påvirker inkluderingen af den irrelevante variabel  $x_3$  vores estimater?

## Inklusion af irrelevante variable

Hvad sker der, hvis man inkluderer en irrelevant variabel?

**OLS er stadig middelret** for alle værdier af  $\beta$ :

$$E(\hat{\beta}_j) = \beta_j$$

Det betyder, at:

$$E(\hat{\beta}_3) = \beta_3 = 0$$

**Er det ligegyldigt at inkludere irrelevante variable?**

Nej! Det påvirker variansen af estimatorne. (Mere om dette nedenfor.)

## Udeladte variable

Hvad sker der, hvis man udelader en relevant variabel?

Antag at den “sande model” opfylder MLR.1-MLR.4 og er givet ved:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u$$

Men vi estimerer i stedet en simpel lineær regressionsmodel:

$$y = \tilde{\beta}_0 + \tilde{\beta}_1 x_1 + \tilde{u}$$

### Underspecificeret model:

- Vi udelader  $x_2$ , selvom det kan være korreleret med  $x_1$ , hvilket kan resultere i bias.
- Hvis  $x_1$  og  $x_2$  ikke er korreleret, opfyldes MLR.4 stadig, og vi kan udelade  $x_2$  uden at introducere bias.



OLS estimatoren i den “underspecificerede model”:

$$\begin{aligned}\tilde{\beta}_1 &= \frac{\sum_{i=1}^n y_i(x_{i1} - \bar{x}_1)}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2} \\&= \frac{\sum_{i=1}^n (\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + u_i)(x_{i1} - \bar{x}_1)}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2} \\&= \beta_1 + \frac{\sum_{i=1}^n (\beta_2 x_{i2} + u_i)(x_{i1} - \bar{x}_1)}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2} \\&= \beta_1 + \beta_2 \frac{\sum_{i=1}^n x_{i2}(x_{i1} - \bar{x}_1)}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2} + \frac{\sum_{i=1}^n u_i(x_{i1} - \bar{x}_1)}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}\end{aligned}$$

Middelværdien af estimatoren:

$$\begin{aligned} E(\tilde{\beta}_1|X) &= \beta_1 + \beta_2 \frac{\sum_{i=1}^n E[x_{i2}(x_{i1} - \bar{x}_1)|X]}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2} + \frac{\sum_{i=1}^n E[u_i(x_{i1} - \bar{x}_1)|X]}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2} \\ &= \beta_1 + \beta_2 \frac{\text{cov}(x_1, x_2)}{\text{var}(x_1)} \end{aligned}$$

Dvs. OLS estimatoren i en “underspecificeret” model er kun middeleret, hvis:

- $\beta_2 = 0$  (modellen er ikke “underspecificeret”).
- $\text{cov}(x_1, x_2) = 0$  (dvs. at  $x_1$  og  $x_2$  er ukorrelerede).

I alle andre tilfælde er estimatoren **ikke middeleret** (også kaldet biased eller skæv).

## Udeladte variable

I mange tilfælde er det ikke muligt at inkludere alle relevante variable i estimationen pga. manglende data.

Dog kan vi typisk sige noget om retningen af bias.

**TABLE 3.2** Summary of Bias in  $\tilde{\beta}_1$  when  $x_2$  Is Omitted in Estimating Equation (3.40)

	$\text{Corr}(x_1, x_2) > 0$	$\text{Corr}(x_1, x_2) < 0$
$\beta_2 > 0$	Positive bias	Negative bias
$\beta_2 < 0$	Negative bias	Positive bias

Bias i modeller med flere variable kan være komplekst (se W3A.4).

- En måde at forstå bias i multivariate modeller er ved hjælp af Frisch-Waugh-teoremet. Det ser vi på nu.

## Bias ved udeladelse af variable: Multivariate case

Antag en model med flere forklarende variable:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + u$$

Udelades  $x_k$ , kan estimerterne af  $\beta_1, \dots, \beta_{k-1}$  blive biased.

**Bias i estimatet af  $\beta_1$ :**

$$E(\tilde{\beta}_1|X) = \beta_1 + \beta_k \frac{\text{cov}(\hat{r}_1, x_k)}{\text{var}(\hat{r}_1)}$$

hvor  $\hat{r}_1$  er residualerne fra regressionen af  $x_1$  på  $x_2, \dots, x_{k-1}$  (brug FWL teoremet).

**Fortegn på bias:**

- Hvis  $\text{cov}(\hat{r}_1, x_k) > 0$ , har bias samme fortegn som  $\beta_k$ .
- Hvis  $\text{cov}(\hat{r}_1, x_k) < 0$ , har bias modsat fortegn af  $\beta_k$ .

**Quiz** Antag at den sande model opfylder MLR.1-MLR.4

$$\log(\text{timeløn}) = \beta_0 + \beta_1 \text{uddannelse} + \beta_2 \text{evner} + u$$

Vi estimerer nu følgende model

$$\log(\text{timeløn}) = \tilde{\beta}_0 + \tilde{\beta}_1 \text{uddannelse} + \tilde{u}$$

Ræk hånden op, hvis du forventer følgende:

1.  $E(\tilde{\beta}_1) > \beta_1$  (positiv bias)
2.  $E(\tilde{\beta}_1) = \beta_1$  (ingen bias)
3.  $E(\tilde{\beta}_1) < \beta_1$  (negativ bias)



**Lad os genbesøge løn ligningen i Python!**

- Use Jupyter Notebook: `03_mlr_examples.ipynb`
- Part 4: Udeladte variable

## Variansen af OLS estimatoren

For lettere at kunne beregne variansen af OLS estimatoren bruger vi fortsat antagelsen om homoskedasticitet.

I MLR modeller er det:

MLR.5 Variansen af fejleddet er konstant

$$\text{Var}(u|x_1, x_2, \dots, x_k) = \sigma^2$$

## Variansen af OLS estimatoren

Med matrixnotation kan antagelserne MLR.5 og MLR.2 skrives som

$$\begin{aligned} \text{Var}(\mathbf{u}|\mathbf{X}) &= E(\mathbf{u}\mathbf{u}'|\mathbf{X}) \\ &= \begin{pmatrix} \text{Var}(u_1|\mathbf{X}) & \text{cov}(u_1, u_2|\mathbf{X}) & \cdots & \text{cov}(u_1, u_n|\mathbf{X}) \\ \text{cov}(u_2, u_1|\mathbf{X}) & \text{Var}(u_2|\mathbf{X}) & \cdots & \text{cov}(u_2, u_n|\mathbf{X}) \\ \vdots & \vdots & \ddots & \vdots \\ \text{cov}(u_n, u_1|\mathbf{X}) & \text{cov}(u_n, u_2|\mathbf{X}) & \cdots & \text{Var}(u_n|\mathbf{X}) \end{pmatrix} \\ &= \begin{pmatrix} \sigma^2 & 0 & \cdots & 0 \\ 0 & \sigma^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma^2 \end{pmatrix} = \sigma^2 \mathbf{I}. \end{aligned}$$

Hvor vi også har benyttet MLR.4:  $E(\mathbf{u}|\mathbf{X}) = \mathbf{0}$



## Variansen af OLS estimatoren: bevis

Som i SLR antager vi, at variansen **ikke** afhænger af  $x$ 'erne, og at kovariansen mellem  $u_i$  og  $u_j$  er nul for alle  $i \neq j$ .

Antagelserne MLR.1-MLR.5 kaldes **Gauss-Markov** antagelserne.

### **Teorem E2** Variansen af OLS estimatoren

Under antagelse af MLR.1-MLR.5 er variansen af OLS estimatoren

$$\text{Var}(\hat{\beta}|\mathbf{X}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$$

# Variansen af OLS estimatoren: bevis

## Ingredienser til bevis

1. Regneregler (**A** og **B** matricer, **x** stok. vektor, *c* skalar)
  - 1.1  $c\mathbf{AB} = \mathbf{AcB} = \mathbf{ABc}$
  - 1.2  $(\mathbf{AB})' = \mathbf{B}'\mathbf{A}'$  og  $(\mathbf{A}')' = \mathbf{A}$
  - 1.3  $\mathbf{AA}^{-1} = \mathbf{I}$  og  $\mathbf{A}^{-1}\mathbf{A} = \mathbf{I}$
  - 1.4 **A** symmetrisk ( $\mathbf{A} = \mathbf{A}'$ ) så er  $\mathbf{A}^{-1}$  (hvis den eksisterer) det også.
  - 1.5  $\text{Var}(\mathbf{Ax}) = \mathbf{A}\text{Var}(x)\mathbf{A}'$
2. Antagelser
  - 2.1 MLR.1: Model  $\mathbf{y} = \mathbf{X}\beta + \mathbf{u}$
  - 2.2 MLR.3: **X** fuld rang
  - 2.3 MLR.4 og MLR.2:  $E(\mathbf{u}|\mathbf{X}) = \mathbf{0}$
  - 2.4 MLR.5 og MLR.2:  $\text{Var}(\mathbf{u}|\mathbf{X}) = \sigma^2\mathbf{I}$
3. Estimator:  $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$

# Variansen af OLS estimatoren: bevis

1. Indsæt sandt  $y$  i  $\hat{\beta}$ :

$$\begin{aligned}\hat{\beta} &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \mathbf{u}) \quad (\text{MLR.1}) \\ &= \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}\end{aligned}$$

2. Tag variansen af  $\hat{\beta}$  givet  $\mathbf{X}$ :

$$\begin{aligned}\text{var}(\hat{\beta}|\mathbf{X}) &= \text{var}((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u} | \mathbf{X}) \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \text{var}(u|\mathbf{X}) \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \\ &= \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \\ &= \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\end{aligned}$$

$\text{var}(\hat{\beta}|\mathbf{X})$  er proportional med  $\sigma^2$  og  $(\mathbf{X}'\mathbf{X})^{-1}$ .

## Variansen af OLS estimatoren

Variansen for hvert  $\hat{\beta}_j$  kan udregnes som:

$$\text{Var}(\hat{\beta}_j|X) = \frac{\sigma^2}{SST_j(1 - R_j^2)} \quad \text{for } j = 1, \dots, k$$

hvor

- $SST_j = \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2$
- $R_j^2$  er  $R^2$  for en regression af  $x_j$  på de øvrige  $x$ 'er.

Vi kan omskrive udtrykket til

$$\text{Var}(\hat{\beta}_j|X) = \frac{\sigma^2}{SST_j \cdot (SSR_j / SST_j)} = \frac{\sigma^2}{SSR_j}$$

hvor  $SSR_j = \sum_{i=1}^n (\hat{r}_{ij} - \bar{r}_j)^2$ . Dette følger af Frisch-Waugh's Teorem.

Husk:

$$\hat{\beta}_j^{SLR} = \frac{\text{cov}(x_j, y)}{\text{var}(x_j)} \quad \rightarrow \quad \text{var}(\hat{\beta}_j^{SLR} | X) = \frac{\sigma^2}{\sum (x_j - \bar{x}_j)^2}$$

$$\hat{\beta}_j^{MLR} = \frac{\text{cov}(\hat{r}_j, y)}{\text{var}(\hat{r}_j)} \quad \rightarrow \quad \text{var}(\hat{\beta}_j^{MLR} | X) = \frac{\sigma^2}{\sum (\hat{r}_j - \bar{\hat{r}}_j)^2}$$

hvor  $\hat{r}_j$  er residualerne fra en regression af  $x_j$  på alle de andre  $x'$ er.

**Quiz:** Antag følgende regressionsmodel:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u$$

hvor variansen på  $\beta_1$  er givet ved:

$$\text{Var}(\hat{\beta}_1|X) = \frac{\sigma^2}{SST_1(1 - R_2^1)}$$

**Spørgsmål:** Ræk hånden op, hvis variansen af  $\hat{\beta}_1$  er *mindst* når:

1.  $x_2$  er positivt korreleret med  $x_1$
2.  $x_2$  er ukorreleret med  $x_1$
3.  $x_2$  er negativt korreleret med  $x_1$

## Estimation af variansen af OLS

Vi mangler nu at estimere  $\hat{\sigma}^2$ .

Estimatoren for variansen af fejlleddet estimeres ved residualerne

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (\hat{u}_i)^2}{n - k - 1} = \frac{SSR}{n - k - 1}. \quad (2)$$

Variansen består af

- Tælleren: Summen af de kvadrerede residualer (SSR)
- Nævneren: Antal obs - antal parametre =  $n - (k + 1) = n - k - 1$

Nævneren sikrer, at estimatoren er middelret (frihedsgradskorrektion).

### **Teorem 3.3:** Middelret estimator af variansen af OLS

Hvis Gauss-Markov antagelserne (MLR.1-MLR.5) holder, så er (2) en middelret estimator for fejlleddets variansen.

## Variansen af OLS estimatoren: Udeladte og irrelevante variable

Hvordan påvirker udeladelsen af en variabel variansen på de øvrige parameter estimater?

Betragt igen modellen

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u$$

Lad  $\hat{\beta}_1$  være estimeret fra en regression af  $y$  på både  $x_1$  og  $x_2$ , og  $\tilde{\beta}_1$  estimeret fra en regression af  $y$  på kun  $x_1$ .

Umiddelbart har vi at

$$\text{var}(\hat{\beta}_1|X) = \frac{\sigma^2}{SST_1(1 - R_1^2)} > \frac{\sigma^2}{SST_1} = \text{var}(\tilde{\beta}_1|X)$$

Hvis  $x_1$  og  $x_2$  er korrelerede og  $\sigma^2$  ikke ændres når  $x_2$  udelades.



## Variansen af OLS estimatoren: Udeladte og irrelevante variable

Vi står med andre ord overfor et “**bias-variance**” trade-off.

Hvis vi inkluderer ekstra variable mindsker vi udeladt variabel bias, men øger umiddelbart variansen.

- Det kan være problematisk i små datasæt.
- Derfor kan det nogle gange betale sig at smide variable (med  $\hat{\beta}_j \approx 0$ ) ud af regressionen for at reducere variansen af de øvirge estimer.

I praksis er det dog ikke helt så simpelt.

- $\sigma^2$  er variansen af fejlleddet.
- I den simple model uden  $x_2$ , er  $x_2$  indeholdt i fejlleddet.
- Derfor vil  $\sigma^2$  ofte stige, når vi undlader  $x_2$ .
- Nogle gange stiger  $\sigma^2$  nok til at øge variansen af  $\hat{\beta}_j$ .

# Variansen af OLS estimatoren: Udeladte og irrelevante variable

Variable	reg_SLR	reg_M~1	reg_M~2
educ	.02821	.02813	.02743
	.00283	.00266	.00265
experience		.01246	.02536
		.00103	.00395
experience2			-.00041
			.00012
_cons	4.5604	4.3791	4.3155
	.03374	.03501	.0396

legend: b/se

$\hat{\beta}$  stant et uændet  
 $\Rightarrow$  bias  $\approx 0$

$Se(\hat{\beta})$  falder  $\Rightarrow \sigma^2$  falder  
når en  $SST_x (1-R^2)$   
stiger

$\hat{\beta}$  stiger  $\Rightarrow$  mindre uændet  
variable bias

$Se(\hat{\beta})$  stiger  $\Rightarrow$

$\sigma^2$  falder mindre ind  
 $SST_x (1-R^2)$  falder.

**OLS er BLUE**

---

## Teorem 3.4: Gauss-Markov Teoremet

Under antagelse af MLR.1–MLR.5 er OLS estimatoren den bedst lineære middelve estimator (**BLUE**).

- **Best:** Mindste varians blandt lineære, middelve estimatore
- **Linear:** Estimatoren er lineær i  $y$ , dvs.  $\tilde{\beta} = Ay$
- **Unbiased:**  $E(\tilde{\beta}) = \beta$
- **Estimator:** Bruger data til at estimere parametre

## Er OLS lineær?

OLS estimatoren i den simple lineære regressionsmodel:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \sum_{i=1}^n y_i w_i, \quad (3)$$

OLS estimatoren kan skrives som en vægtet sum af  $y$ 'erne, hvor  $w_i = \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$ . Dette er definitionen på en lineær estimator.

**Om vægtene gælder:**

$$\sum_{i=1}^n w_i = 0, \quad \sum_{i=1}^n w_i x_i = 1 \quad (4)$$

Disse egenskaber sikrer, at estimatoren er uafhængig af konstantleddet og korrekt skaleret i forhold til  $x_i$ .

Vi kan konstruere en alternativ lineær estimator ved at vælge andre vægte:

$$\tilde{\beta}_1 = \sum_{i=1}^n y_i \tilde{w}_i \quad (5)$$

Under MLR.1-MLR.4 vil den alternative estimator kun være middelret, hvis vægterne opfylder følgende betingelser:

$$\sum_{i=1}^n \tilde{w}_i = 0, \quad \sum_{i=1}^n \tilde{w}_i x_i = 1 \quad (6)$$

**Spørgsmål:** Hvorfor skal disse betingelser opfyldes for at estimatoren er middelret? (Næste slide)

**Lineær estimator:**

$$\tilde{\beta}_1 = \sum y_i \tilde{w}_i$$

**1) Indsæt sandt  $y$  (MLR.1)**

$$\tilde{\beta}_1 = \sum (\beta_0 + \beta_1 x_i + u_i) \tilde{w}_i = \beta_0 \sum \tilde{w}_i + \beta_1 \sum x_i \tilde{w}_i + \sum u_i \tilde{w}_i$$

**2) Tag  $E(\tilde{\beta}_1|X)$ :**

$$E(\tilde{\beta}_1|X) = \beta_0 \sum \tilde{w}_i + \beta_1 \sum x_i \tilde{w}_i + \sum E(u_i|X) \tilde{w}_i$$

Under MLR.4,  $E(u_i|X) = 0$ , så for at estimatoren skal være middelfret:

$$E(\tilde{\beta}_1|X) = \beta_1 \quad \text{hvis} \quad \sum \tilde{w}_i = 0 \quad \text{og} \quad \sum x_i \tilde{w}_i = 1$$

En alternativ lineær middelfret estimator (i SLR model):

$$\begin{aligned}\tilde{w}_1 &= \frac{-1}{x_n - x_1} \\ \tilde{w}_j &= 0 \quad j = 2, \dots, n-1 \\ \tilde{w}_n &= \frac{1}{x_n - x_1}\end{aligned}$$

Den alternative estimator

$$\hat{\beta}_1 = \frac{y_n - y_1}{x_n - x_1}.$$

Estimatoren er middelfret ( $\sum \tilde{w}_i = 1$  og  $\sum x_i \tilde{w}_i = 1$ )

- ...men vi foretrækker OLS, fordi den har mindre varians.
- Der findes alternative “ikke-åndsvage” estimators, fx matching.



# Gauss-Markov teoremet: Bevis

## Ingredienser til bevis

1. Regneregler (**A** og **B** matricer, **x** stok. vektor, *c* skalar)
  - 1.1  $c\mathbf{AB} = \mathbf{A}c\mathbf{B} = \mathbf{AB}c$
  - 1.2  $(\mathbf{AB})' = \mathbf{B}'\mathbf{A}'$  og  $(\mathbf{A}')' = \mathbf{A}$
  - 1.3  $\mathbf{AA}^{-1} = \mathbf{I}$  og  $\mathbf{A}^{-1}\mathbf{A} = \mathbf{I}$
  - 1.4  $\text{Var}(\mathbf{Ax}) = \mathbf{A}\text{Var}(x)\mathbf{A}'$
  - 1.5 En kvadratisk, symmetrisk matrix ( $\mathbf{A} = \mathbf{A}'$ ) er positiv semi definit.
  - 1.6 En idempotent matrix ( $\mathbf{A} = \mathbf{AA}$ ) er kvadratisk.
  - 1.7 Hvis **A** er positiv semi definit og  $\mathbf{q}'\mathbf{A}\mathbf{q}$  en skalar, gælder  $\mathbf{q}'\mathbf{A}\mathbf{q} > 0$ .
2. Antagelser
  - 2.1 MLR.1: Model  $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$
  - 2.2 MLR.3: **X** fuld rang
  - 2.3 MLR.4 og MLR.2:  $E(\mathbf{u}|\mathbf{X}) = \mathbf{0}$
  - 2.4 MLR.5 og MLR.2:  $\text{Var}(\mathbf{u}|\mathbf{X}) = \sigma^2\mathbf{I}$
3. Variansen af OLS estimator:  $\text{Var}(\hat{\boldsymbol{\beta}}|\mathbf{X}) = \sigma^2\mathbf{X}'\mathbf{X}^{-1}$

## Gauss-Markov teoremet: Bevis

Vi starter med at betragte alle lineære middeltrette estimatorer (LUE).

Alle estimatorer i denne kategori kan skrives som

$$\tilde{\beta} = \mathbf{A}'\mathbf{y} \quad \text{hvor} \quad \mathbf{A}'\mathbf{X} = \mathbf{I}$$

Under MLR.1:  $\mathbf{y} = \mathbf{X}\beta + \mathbf{u}$  og derfor

$$\tilde{\beta} = \mathbf{A}'(\mathbf{X}\beta + \mathbf{u}) = \mathbf{A}'\mathbf{X}\beta + \mathbf{A}'\mathbf{u}$$

Under MLR.4:  $E(\mathbf{u}|\mathbf{X}) = 0$

$$E(\tilde{\beta}|\mathbf{X}) = \mathbf{A}'\mathbf{X}\beta + \mathbf{A}'E(\mathbf{u}|\mathbf{X}) = \beta$$

og derfor  $\mathbf{A}'\mathbf{X} = \mathbf{I}$  for at bevare middeltrethed.

## Gauss-Markov teoremet: Bevis

Nu skal vi kigge på “Best” delen.

Til det skal vi bruge variansen på vores (alternative) LUE

$$\text{Var}(\tilde{\beta}|X) = \text{Var}(\mathbf{A}'\mathbf{y}|\mathbf{X}) = \text{Var}(\mathbf{A}'\mathbf{X}\beta|X) + \text{Var}(\mathbf{A}'\mathbf{u}|\mathbf{X})$$

Første led er 0 (fordi  $\text{Var}(\mathbf{A}'\mathbf{X}\beta|X) = 0$ ).

Andet led:

$$\text{Var}(\mathbf{A}'\mathbf{u}|\mathbf{X}) = \mathbf{A}'\text{Var}(\mathbf{u}|\mathbf{X})\mathbf{A} = \sigma^2\mathbf{A}'\mathbf{A} \quad (\text{MLR.5})$$

## Gauss-Markov teoremet: Bevis

Dvs. forskellen i variansen på vores alternative LUE og OLS er

$$\text{Var}(\tilde{\beta}|X) - \text{Var}(\hat{\beta}|X) = \sigma^2 \mathbf{A}'\mathbf{A} - \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$$

Brug  $\mathbf{A}'\mathbf{X} = \mathbf{I}$  til at gange fra venstre og højre:

$$= \sigma^2 \mathbf{A}' [\mathbf{I} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'] \mathbf{A}$$

Hvor  $\mathbf{M} = \mathbf{I} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ , der er symmetrisk og idempotent ( $\mathbf{M}\mathbf{M} = \mathbf{M}$ ).

$\mathbf{M}$  er positiv semidefinit, så  $\mathbf{A}'\mathbf{M}\mathbf{A} \geq 0$ , således at

$$\mathbf{q}' [\text{Var}(\tilde{\beta}|X) - \text{Var}(\hat{\beta}|X)] \mathbf{q} \geq 0 \quad \text{for alle } \mathbf{q}.$$

### Hvorfor er Gauss-Markov Teoremet vigtigt?

Teoremet siger, at hvis  $\tilde{\beta}$  er en anden lineær middelværdi estimator, så vil OLS estimatoren  $\hat{\beta}$  altid have mindre varians:

$$\text{Var}(\hat{\beta}_j|X) \leq \text{Var}(\tilde{\beta}_j) \quad \text{for } j = 0, \dots, k$$

Desuden gælder det, at for enhver lineær kombination af parameterestimatorerne er variansen af OLS mindre, fx

$$\text{Var}(\hat{\beta}_i - \hat{\beta}_j|X) \leq \text{Var}(\tilde{\beta}_i - \tilde{\beta}_j|X)$$

## Gauss-Markov teoremet: Relevance

Hvorfor er det relevant at beregne

$$\mathbf{q}' \text{Var}(\hat{\beta}|\mathbf{X})\mathbf{q}$$

**Eksempler:**

$$\text{var}(\hat{\beta}_1|\mathbf{X})$$

$$\text{var}(\hat{\beta}_1 - \hat{\beta}_2|\mathbf{X})$$

$$\text{var}(a\hat{\beta}_1 + b\hat{\beta}_2|\mathbf{X}) = a^2 \text{var}(\hat{\beta}_1|\mathbf{X}) + b^2 \text{var}(\hat{\beta}_2|\mathbf{X}) + 2ab \text{cov}(\hat{\beta}_1, \hat{\beta}_2|\mathbf{X})$$

## Gauss-Markov teoremet: Relevance

Lad:  $\mathbf{q} = \begin{bmatrix} a \\ b \end{bmatrix}$  (vektor af vægte)

$$\text{Var}(\hat{\beta}|\mathbf{X}) = \begin{pmatrix} \text{var}(\hat{\beta}_1|\mathbf{X}) & \text{cov}(\hat{\beta}_1, \hat{\beta}_2|\mathbf{X}) \\ \text{cov}(\hat{\beta}_1, \hat{\beta}_2|\mathbf{X}) & \text{var}(\hat{\beta}_2|\mathbf{X}) \end{pmatrix}$$

Så gælder:

$$\begin{aligned} \mathbf{q}' \text{Var}(\hat{\beta}|\mathbf{X}) \mathbf{q} &= (\mathbf{a} \ \mathbf{b}) \begin{pmatrix} \text{var}(\hat{\beta}_1|\mathbf{X}) & \text{cov}(\hat{\beta}_1, \hat{\beta}_2|\mathbf{X}) \\ \text{cov}(\hat{\beta}_1, \hat{\beta}_2|\mathbf{X}) & \text{var}(\hat{\beta}_2|\mathbf{X}) \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} \\ &= a^2 \text{var}(\hat{\beta}_1|\mathbf{X}) + b^2 \text{var}(\hat{\beta}_2|\mathbf{X}) + 2abcov(\hat{\beta}_1, \hat{\beta}_2|\mathbf{X}) \end{aligned}$$

## Opsummering

---



Meget af hvad vi lærte ved SLR gælder også for MLR

- MLR.1-MLR.4  $\implies$  OLS er middelret.
- MLR.5  $\implies$  Vi kan udregne variansen af OLS.

Frish-Waugh's Teorem

- MLR kan fortolkes som SLR, hvor vi "renser"  $x$ 'erne for deres korrelation med andre variable.

Udeladte og irrelevante variable

- Inklusion af irrelevante variable medfører ikke bias, men risikerer at øge variansen på de øvrige estimater.
- Udeladelsen af relevante variable medfører bias, hvis de er korreleret med variablene i modellen.

